

# Departamento de Electrónica, Sistemas e Informática

## **Computer Systems Engineering**

## **Big Data Processing**

#### Autumn 2025

**Final Project: Batch Processing** 

Date: October, 2025

Student Name: Diego Orozco Alvarado

**Professor**: Pablo Camarillo Ramirez

## Introduction

En este notebook se busca diseñar e implementar un pipeline por lotes que simula la ingesta y procesamiento de telemetría tipo Waze. El objetivo es:

- Generar datos (simulados) de usuarios/dispositivos que reportan coordenadas, alertas y solicitudes de ruta.
- Procesar/limpiar y manejar los datos con PySpark (transformaciones: normalización, agregados, joins).
- Se usara PostgreSQL para permitir persistiencia en resultados como sistema relacional para consultas analíticas y downstream.

#### Problema:

Los conductores dependen de aplicaciones de navegación como Waze o maps para decidir las mejores rutas en tiempo real. Sin embargo, estas aplicaciones deben procesar grandes volúmenes de datos generados por miles de usuarios

simultáneamente, incluyendo información de ubicación (GPS), velocidad, tráfico, accidentes, obras, cierres de calles, etc.

El problema principal sucede al recolectar, transformar y almacenar de forma eficiente ya que estos son datos masivos necesarios ya que proveen información útil y actualizada a todos los usuarios. Por este motivo el objetivo de este proyecto es diseñar e implementar un pipeline de datos batch que procese eventos generados por los usuarios de Waze (por decir alguna), limpie y transforme la información, y la persista en una base de datos relacional para su análisis posterior.

## **Dataset**

#### Nota:

Se eligio "It can be produced by a python script (check the FakerLinks to an external site. library). In this case, the script that produce the data should be posted in your module (in the lib directory)"

WARNING: Using incubator modules: jdk.incubator.vector 25/10/25 19:41:34 WARN NativeCodeLoader: Unable to load native-hadoop librar y for your platform... using builtin-java classes where applicable Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.proper ties Setting default log level to "WARN". To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLog Level(newLevel).

```
In [2]: from diego_orozco.spark_utils import SparkUtils
from pyspark.sql.functions import col, lit, when
from pyspark.sql import SparkSession

base_path = "/opt/spark/work-dir/data"

spark = SparkSession.builder.getOrCreate()
```

```
waze_schema = SparkUtils.generate_schema([
    ("event_id", "string"),
    ("device_id", "string"),
    ("user_id", "string"),
    ("timestamp", "timestamp"),
    ("lat", "double"), ("lon", "double"),
    ("speed_kmh", "double"),
    ("heading", "double"),
    ("event_type", "string"),
("alert_type", "string"),
     ("route_points", "array<array<double>>")
])
df_waze = spark.read \
     .schema(waze_schema) \
     .json(base_path + "/data_proy/data_proy_waze/")
df_waze.show(5, truncate=False)
df_waze.printSchema()
```

```
[Stage 0:> (0 + 1) / 1]
```

```
|device id|user id |timestamp
levent id
|a78e981e-bb06-41cb-a782-615b28708e5d|dev 1144 |user 1680|2025-10-26 18:46:5
0.335848|19.498477|-99.206313|81.2 |321.18 |location |NULL
|74f6852d-bb39-45da-9fc5-6b1c73fa3860|dev 1906 |user 8280|2025-10-25 22:39:5
5.335848|19.304904|-99.249646|72.24 |202.05 |location |NULL
|b8357bd6-8ada-4a56-a1b6-148f29db1027|dev 2279 |user 107 |2025-10-26 19:09:4
1.335848|19.410651|-99.147757|91.06 |57.48 |alert |pothole
                                                       NULL
|88a72c16-8d4a-42bc-b4c8-18c8865eb0bc|dev_838 |user_1520|2025-10-26 07:53:1
7.335848|19.354958|-99.057683|45.59 |129.23 |location |NULL |NULL
|9889f32e-64ba-4024-b9de-1b4a339c3b50|dev_4393 |user_2046|2025-10-26 08:01:2
2.335848|19.516362|-99.06736 |116.77 |136.27 |location |NULL
only showing top 5 rows
root
|-- event id: string (nullable = true)
 |-- device_id: string (nullable = true)
 |-- user id: string (nullable = true)
 |-- timestamp: timestamp (nullable = true)
 |-- lat: double (nullable = true)
 |-- lon: double (nullable = true)
 |-- speed kmh: double (nullable = true)
 |-- heading: double (nullable = true)
 |-- event type: string (nullable = true)
 |-- alert type: string (nullable = true)
 |-- route_points: array (nullable = true)
    |-- element: array (containsNull = true)
    | |-- element: double (containsNull = true)
```

Columna	Tipo	Significado
event_id	string	Identificador único de cada evento registrado por el usuario o dispositivo.
device_id	string	Identificador del dispositivo que envía la información (móvil, GPS, etc.).
user_id	string	Identificador del usuario que reporta o genera el evento.
timestamp	timestamp	Momento exacto en que ocurrió el evento (fecha y hora).
lat	double	Latitud de la ubicación del evento.

Columna	Tipo	Significado
lon	double	Longitud de la ubicación del evento.
speed_kmh	double	Velocidad del vehículo en kilómetros por hora en el momento del evento.
heading	double	Dirección del vehículo en grados (0–360°) en el momento del evento.
event_type	string	Tipo de evento: "location" (solo ubicación) o "alert" (reportes de usuario).
alert_type string	Subtipo del evento si event_type = alert, por ejemplo "pothole", "traffic", "police", "accident".	
route_points	array <array></array>	Lista de puntos GPS que forman una ruta solicitada por el usuario (cada subarray contiene [lat, lon]).

# **Transformations and Actions**

```
In [3]: from pyspark.sql.functions import col, when, lit, year, month, dayofmonth, h
        df selected = df waze.select(
            "event id",
            "user_id",
            "timestamp",
            "lat",
            "lon",
            "speed_kmh",
            "event_type",
            "alert type"
        df with time = df selected.withColumns({
            "year": year(col("timestamp")),
            "month": month(col("timestamp")),
            "day": dayofmonth(col("timestamp")),
            "hour": hour(col("timestamp"))
        })
        df_with_speed_cat = df_with_time.withColumn(
            "speed_category",
            when(col("speed kmh") < 30, lit("low"))</pre>
             .when((col("speed_kmh") >= 30) & (col("speed_kmh") < 70), lit("medium"))
            .otherwise(lit("high"))
        df_filtered = df_with_speed_cat.filter(
            (col("event_type") == "alert") &
            (col("alert type").isin(["accident", "traffic", "police", "pothole"]))
        df aggregated = df filtered.groupBy("event type", "speed category") \
             .agg(avg("speed_kmh").alias("avg_speed"), count("*").alias("num_events")
```

## Persistence Data

### Justificación:

Se selecciona PostgreSQL por las siguientes razones:

- Permite consultas SQL avanzadas para análisis posteriores.
- Es ideal para almacenar datos agregados y limpios con relaciones entre usuarios, segmentos y eventos.
- Permite escalar horizontalmente y soporta tipos de datos complejos (como JSONB) si se requiere.

```
In [4]: jdbc_url = "jdbc:postgresql://postgres-iteso:5432/postgres"
table_name = "proy_data_waze_transformed"
```


df aggregated.write \

```
.format("jdbc") \
           .option("url", jdbc_url) \
           .option("dbtable", table_name) \
           .option("user", "postgres") \
           .option("password", "Admin@1234") \
           .option("driver", "org.postgresql.Driver") \
           .mode("overwrite") \
           .save()
       print("DataFrame successfully written into a PosgreSQL DB !")
                                                                      (0 + 1)
      [Stage 3:>
      / 1]
      DataFrame successfully written into a PosgreSQL DB!
In [5]: |jdbc_url = "jdbc:postgresql://postgres-iteso:5432/postgres"
       db properties = {
             "user": "postgres",
             "password": "Admin@1234",
             "driver": "org.postgresql.Driver"
         }
       df = spark.read \
           .jdbc(url=jdbc_url, table=table_name, properties=db_properties)
       df.printSchema()
       df.show(5, truncate=False)
      root
       |-- event type: string (nullable = true)
       |-- speed category: string (nullable = true)
       |-- avg_speed: double (nullable = true)
       |-- num events: long (nullable = true)
      +----+
      |49.87504198152819 |2382
      |alert
                 |medium
      |alert |high |95.10860875466587 |2947 |
|alert |low |14.936458893068247 |1861
```

Columna	Tipo	Significado
event_type	string	Tipo de evento considerado para análisis: "alert", "traffic", "accident", "police" (ahorita se filtro a solo alert).
speed_category	string	Categoría de velocidad según speed_kmh: "low" (<30 km/h), "medium" (30–70 km/h), "high" (>70 km/h).
avg_speed	double	Velocidad promedio calculada de los eventos agrupados por event_type y speed_category.

Columna	Tipo	Significado
num_events	long	Número total de eventos que cayeron en cada combinación de event_type y speed_category.

## DAG



#### Details for Stage 1 (Attempt 0)

Resource Profile Id: 0
Total Time Across All Tasks: 4 s
Locality Level Summary: Process local: 2
Input Size / Records: 17.3 MiB / 7190
Shuffle Write Size / Records: 610.0 B / 6
Associated Job Ids: 1

